

Sistema de recomendación de películas basado en contenido

Informe técnico de evaluación de modelo

Trabajo Final Integrador — Introducción al Procesamiento del Lenguaje Natural

Junio de 2026

1. Resumen

Se diseñó y evaluó un sistema de recomendación de películas basado en contenido, sobre un corpus de aproximadamente 4.970 películas en español (sinopsis, género, año, director y palabras clave) y 14 perfiles de usuario simulados, cada uno con un historial de 5 películas y una consulta ("query") en lenguaje natural. El objetivo fue generar, para cada usuario, una lista de 5 recomendaciones.

Se implementaron y compararon tres enfoques de representación y ponderación, resumidos en la Tabla 1:

- Enfoque 1 — Embeddings con Sentence-Transformer: representación semántica de query e historial concatenados en un único vector.
- Enfoque 2 — Embeddings ponderados con LLM: separa query e historial, y un LLM clasifica la intención de la consulta para definir cuánto peso darle a cada señal.
- Enfoque 3 — TF-IDF ponderado con LLM: misma lógica de ponderación que el Enfoque 2, pero sobre una representación léxica (TF-IDF) en lugar de embeddings semánticos.

Tabla 1. Métricas promedio por enfoque, sobre los 9 perfiles de usuario con géneros esperados etiquetados.

Enfoque	Recall	Precisión	F1
Enfoque 1	88.9%	91.1%	88.8%
Enfoque 2	77.8%	82.2%	76.1%
Enfoque 3	88.9%	80.0%	83.1%

El Enfoque 1 obtuvo las mejores métricas agregadas ($F1 = 88.8\%$), seguido por el Enfoque 3 ($F1 = 83.1\%$) y el Enfoque 2 ($F1 = 76.1\%$). Sin embargo, la conclusión central de este trabajo es que estas métricas, basadas en coincidencia de género, sobreestiman sistemáticamente la calidad real de las recomendaciones: la revisión manual caso por caso muestra usuarios con $F1$ del 100% que reciben películas que no cumplen con lo pedido en la query, y casos donde una caída en las métricas coincide con una mejora cualitativa real. Esta discrepancia, más que el ranking entre enfoques, es el hallazgo principal a tener en cuenta antes de llevar cualquiera de estos modelos a producción.

2. Diseño del sistema

2.1 Datos y representación de las películas

Cada película se representó como un único texto que concatena nombre, sinopsis, director, género y palabras clave, tras un pipeline de limpieza (decodificación de entidades HTML, eliminación de caracteres extraños y espacios redundantes). Esta decisión es central: define

qué información puede "entender" el sistema por similitud, y excluye de entrada cualquier atributo que el corpus no provee — duración, elenco, calidad de actuación, ritmo narrativo — que varias queries de usuario sí mencionan.

Para los enfoques 2 y 3, la representación de cada usuario combina dos señales por separado: el embedding (o vector TF-IDF) de su query, y el promedio de los embeddings de las 5 películas de su historial. La forma de combinarlas — qué peso le da cada una y en qué dirección buscar — depende de la clasificación de intención descrita en la sección 2.2.

2.2 Clasificación de intención con LLM

Para los enfoques 2 y 3 se utilizó gemini-2.5-flash-lite para clasificar cada query en una de cuatro categorías, cada una con un esquema de pesos y dirección de búsqueda asociado:

- **normal**: la query describe atributos evaluables por el sistema (género, tema, trama). Se prioriza la query por sobre el historial.
- **historial_positivo**: la query es vaga o pide algo similar a lo habitual. Se prioriza el historial.
- **historial_negativo**: la query pide explícitamente algo distinto a lo habitual. Se prioriza el historial, pero se buscan las películas menos similares.
- **no_evaluable**: la query depende de atributos que el sistema no puede medir (calidad de actuación, duración, etc.). Se trata como historial_positivo, pero se mantiene como categoría separada para cuantificar esta limitación del sistema.

La clasificación resultó, en general, coherente con la redacción de las queries, incluyendo casos de frontera no triviales: una query como "quiero algo distinto a lo de siempre, pero tampoco tan raro" fue correctamente identificada como historial_negativo, y queries que combinan un pedido específico con un atributo no evaluable (por ejemplo, mencionar "estilo visual" dentro de una consulta por lo demás concreta) fueron clasificadas como normal cuando el resto de la query aportaba suficiente señal evaluable. La calidad de este enfoque depende críticamente de que la clasificación sea correcta: un error de categoría cambia drásticamente los pesos y hasta la dirección de búsqueda.

2.3 Métrica de evaluación

No existe en el corpus un listado de "películas correctas" por usuario, por lo que se utilizó el género como aproximación de relevancia. Para los 9 perfiles de usuario con preferencias claras y consistentes ("definidos"), se etiquetaron a mano 3 géneros esperados por usuario, a partir de su historial y su query. Sobre esa base se calculó, por usuario:

- **Recall**: proporción de géneros esperados que aparecen en el top-5 recomendado.
- **Precision**: proporción de películas del top-5 que tienen al menos un género esperado.
- **F1**: media armónica de ambas.

Los 5 perfiles restantes (difíciles de clasificar) no se incluyeron en la evaluación cuantitativa por no admitir un etiquetado confiable, pero sí se usaron para el análisis cualitativo, ya que son los casos donde la ponderación dinámica de los enfoques 2 y 3 muestra su mayor potencial.

3. Resultados por enfoque

3.1 Enfoque 1 — Embeddings con Sentence-Transformer

Este enfoque concatena query e historial en un único texto y lo proyecta con el modelo multilingüe *paraphrase-multilingual-MiniLM-L12-v2*, recomendando por similitud coseno contra el espacio de películas.

Tabla 2. Top-5 de recomendaciones por usuario — Enfoque 1.

Usuario	#1	#2	#3	#4	#5
Valentina	Tránsito (2006)	La mano que mece la cuna (1992)	Begotten (1991)	Truly Madly Deeply (1992)	La novia cadáver (2005)
Rodrigo	Historia de un soldado (1985)	Monster's Ball (2002)	Vida de este chico (1994)	Una árida estación blanca (1989)	Gorilas en la niebla (1989)
Camila	Ahora los padres son ellos (2010)	Mira quién habla también (1991)	Más allá del odio (2005)	Swingers (1997)	La familia Addams (1992)
Tomás	La red (1995)	Pulse (Conexión) (2007)	El cortador de césped (1992)	Nivel 13 (1999)	Proyecto Brainstorm (1983)
Lucía	Tránsito (2006)	Begotten (1991)	Durmiendo con su enemigo (1991)	La mano que mece la cuna (1992)	Crónica de un engaño (2010)
Martín	Como pez en el agua (1998)	El negociador (1997)	Persecución extrema (2007)	Albino Alligator (1997)	¡Que te calles! (2004)
Sofía	Ray (2005)	Hedwig and the Angry Inch (2001)	La diva (1981)	Miedo y asco en Las Vegas (1999)	El corazón del ángel (1987)
Diego	Hollywood: Departamento de homicidios (2003)	Más fuerte que el odio (1988)	The Fast and the Furious (A todo gas) (2001)	Max Payne (2008)	L.A. Confidential (1997)
Elena	Brothers (Hermanos) (2010)	Algo en común (2005)	El turista accidental (1989)	Todos están bien (2010)	La vida de Pi (2012)

Tabla 3. Métricas por usuario — Enfoque 1.

Usuario	Recall	Precision	F1
Valentina	100.0%	100.0%	100.0%
Rodrigo	66.7%	60.0%	63.2%
Camila	100.0%	100.0%	100.0%
Tomás	100.0%	100.0%	100.0%
Lucía	33.3%	80.0%	47.1%
Martín	100.0%	100.0%	100.0%
Sofía	100.0%	80.0%	88.9%
Diego	100.0%	100.0%	100.0%
Elena	100.0%	100.0%	100.0%
Promedio	88.9%	91.1%	88.8%

Es el enfoque con mejores métricas agregadas, pero también el que mejor ilustra su propia limitación: usuarios con F1 del 100% recibieron recomendaciones que no cumplen la query en términos de trama. El caso de Camila es representativo — las 5 recomendaciones son comedias (cumpliendo el género explícito de la query), pero ninguna cumple con la situación particular que pide ("una relación que empieza de forma ridícula o accidental"). El sistema captura el género porque está mencionado explícitamente, pero no tiene forma de verificar la trama específica más allá de la similitud textual general. Otro patrón recurrente es que, al mezclar query e historial en un solo vector, una query con poco contenido propio (como la de un usuario que pide "algo distinto" a su historial) termina dominada por el historial, contradiciendo la intención real del pedido.

3.2 Enfoque 2 — Embeddings ponderados con LLM

Separa el embedding de la query del embedding del historial (promedio de las 5 películas vistas) y los combina con un promedio ponderado según la categoría asignada por el LLM.

Tabla 4. Top-5 de recomendaciones por usuario — Enfoque 2.

Usuario	#1	#2	#3	#4	#5
Valentina	El ente (1983)	Tránsito (2006)	Femme Fatale (2003)	Alone in the Dark (2006)	The Ring (La señal) (2003)
Rodrigo	Enemigo público (1999)	El asesinato de Richard Nixon (2006)	La noche cae sobre Manhattan (1997)	Dark Blue (2004)	Sospechoso (1988)
Camila	Escuela de novatos (2004)	La pareja basura (1991)	Misterioso asesinato en Manhattan (1994)	La comedia sexual de una noche de verano (1982)	Ensalada de gemelas (1988)

Usuario	#1	#2	#3	#4	#5
Tomás	Proyecto Brainstorm (1983)	Pequeños guerreros (1998)	El asesinato de Richard Nixon (2006)	Paycheck (2004)	La gran huida (1984)
Lucía	Daredevil (2003)	Virtuosity (1995)	Número 9 (2010)	Code Geass: Lelouch of the Rebellion (2006)	Cuentos de Terramar (2006)
Martín	Plan oculto (2006)	Supercañeras: El internado puede ser una fiesta (2002)	Sin motivo aparente (2003)	Albino Alligator (1997)	Heat (1996)
Sofía	Aquarius (1987)	Once (2007)	Ragtime (1982)	El vagón de la muerte (2008)	Slacker (1991)
Diego	El único (2002)	The Punisher (El castigador) (2004)	El coche fantástico (N/A)	Snake Eyes (Ojos de serpiente) (1998)	Una historia de violencia (2005)
Elena	El orfanato (2007)	A la deriva (2006)	Red Rock West (1995)	Reeker (2006)	La tostadora valiente (1994)

Tabla 5. Métricas por usuario — Enfoque 2.

Usuario	Recall	Precision	F1
Valentina	100.0%	100.0%	100.0%
Rodrigo	66.7%	80.0%	72.7%
Camila	33.3%	100.0%	50.0%
Tomás	100.0%	80.0%	88.9%
Lucía	100.0%	60.0%	75.0%
Martín	100.0%	100.0%	100.0%
Sofía	100.0%	60.0%	75.0%
Diego	66.7%	100.0%	80.0%
Elena	33.3%	60.0%	42.9%
Promedio	77.8%	82.2%	76.1%

Las tres métricas cayeron respecto al Enfoque 1. Sin embargo, la inspección manual matiza esta caída: para Valentina, la recomendación de mayor score ("El ente", 1983) describe casi exactamente la situación de su query — una mujer atacada por una entidad invisible — algo que el Enfoque 1 no había logrado priorizar con tanta claridad. Para Rodrigo, el F1 es menor que en el Enfoque 1, pero todas las películas recomendadas tratan efectivamente sobre corrupción política, mostrando mayor coherencia temática aunque el género formal asignado no siempre coincida con el esperado. Este patrón — caída en la métrica, mejora cualitativa — es

el que motiva la advertencia central de este informe sobre la confiabilidad de la métrica basada en género.

Sobre los perfiles ambiguos, donde este enfoque fue diseñado para aportar más valor: cuando un usuario pide explícitamente algo distinto a su historial, el sistema invierte correctamente la dirección de búsqueda y prioriza el historial como ancla, en lugar de dejar que la query (con poco contenido propio) domine el resultado sin criterio, que era la falla observada en el Enfoque 1 para este tipo de casos.

3.3 Enfoque 3 — TF-IDF ponderado con LLM

Aplica la misma lógica de ponderación del Enfoque 2 (separar query e historial, combinar según la clasificación del LLM), pero sobre una representación TF-IDF. Previo a la vectorización se tradujeron al español las palabras clave en inglés y se aplicó lematización, dado que TF-IDF — a diferencia de los embeddings — trata cada variante léxica como una dimensión independiente sin relación semántica entre sí.

Tabla 6. Top-5 de recomendaciones por usuario — Enfoque 3.

Usuario	#1	#2	#3	#4	#5
Valentina	Inseparables (1989)	Cabin fever 2 (2011)	Los ríos de color púrpura 2: Los ángeles del apocalipsis (2004)	El hombre sin sombra (2000)	Suavemente me mata (2002)
Rodrigo	Maleficio (2006)	El expreso de Elmira (2008)	Buenas noches, y buena suerte. (2006)	El asesinato de Richard Nixon (2006)	Machuca (2004)
Camila	Loverboy (1989)	Padre Made in USA (2005)	Forasteros en Nueva York (1999)	Testigo accidental (1990)	La posesión (1981)
Tomás	Gothika (2004)	Halloweentown: ¡Qué familia la mía! (1998)	Así se hace (2001)	El aceite de la vida (1993)	Joint Security Area (JSA) (2000)
Lucía	V de Vendetta (2006)	Samurai Jack (2017)	Haru en el reino de los gatos (2002)	Cheque en blanco (1994)	Libertad para morir (1991)
Martín	Phantoms (1998)	Los idiotas (1999)	La cena (2010)	Pret-a-porter (1995)	La rebelión de las máquinas (1986)
Sofía	The Shield: Al margen de la ley (2003)	Begotten (1991)	Adiós, muchachos (1989)	Los fabulosos Baker Boys (1990)	El rey de la comedia (1982)
Diego	Las aventuras de Jackie Chan (2000)	Justa venganza (2005)	Pusher 3: Soy el ángel de la muerte (2005)	Air America (1990)	Luna negra (1987)
Elena	Padre Ted (1995)	Algo en común (2005)	Click (2006)	Bienvenido a Mooseport (2004)	South Park (1997)

Tabla 7. Métricas por usuario — Enfoque 3.

Usuario	Recall	Precision	F1
Valentina	100.0%	80.0%	88.9%
Rodrigo	100.0%	100.0%	100.0%
Camila	66.7%	80.0%	72.7%
Tomás	66.7%	40.0%	50.0%
Lucía	100.0%	60.0%	75.0%
Martín	66.7%	80.0%	72.7%
Sofía	100.0%	80.0%	88.9%
Diego	100.0%	100.0%	100.0%
Elena	100.0%	100.0%	100.0%
Promedio	88.9%	80.0%	83.1%

El desempeño quedó en un punto intermedio entre los dos enfoques anteriores, mejor de lo esperado para una representación puramente léxica. Esto se explica porque buena parte de las queries comparten vocabulario explícito con las sinopsis del corpus (palabras como "amenaza", "corrupción", "hechos reales" aparecen tanto en la query como en la descripción de la película recomendada), lo que favorece a TF-IDF en pedidos literales. La contracara se observa en los perfiles ambiguos: para usuarios clasificados como `no_evaluable`, el sistema recurre a coincidencias de historial que en ocasiones son demasiado literales — por ejemplo, recomendar la secuela directa de una película ya vista, o un título con coincidencia parcial de nombre en lugar de una similitud temática real.

4. Por qué desconfiar de las métricas

El patrón más consistente a lo largo de los tres enfoques es la desconexión entre las métricas cuantitativas y la calidad real evaluada manualmente. Esto tiene una causa estructural: el género se usa simultáneamente como parte de la representación de la película (a través del texto unificado) y como criterio de evaluación, lo cual genera una validación parcialmente circular — un sistema puede acertar el género "porque está mencionado en el texto" sin haber entendido la situación, el tono o la trama que la query realmente describe.

A esto se suma que ninguno de los tres enfoques tiene acceso a información que varias queries piden de forma explícita: duración ("que no sea muy larga"), calidad de actuación, ritmo narrativo o estilo visual. Para cuantificar esta limitación se introdujo la categoría `no_evaluable` en la clasificación del Enfoque 2, en lugar de ignorarla o forzarla a encajar en otra categoría.

En conjunto, estos dos factores — circularidad de la métrica y ausencia de atributos relevantes en el corpus — explican mejor las diferencias de desempeño observadas que la elección del modelo de representación en sí.

5. Limitaciones

- Dataset pequeño con historial escaso: 14 usuarios con 5 películas cada uno es insuficiente para una validación estadísticamente robusta.
- Etiquetado subjetivo: los géneros esperados por usuario se asignaron manualmente, sin un segundo evaluador ni consenso.
- Géneros del corpus potencialmente incorrectos o incompletos: se observaron varios casos de películas con géneros mal asignados o géneros temáticamente relevantes ausentes.
- Métricas permisivas: una película con un solo género esperado en común ya se considera "correcta" en el cálculo, aun si el resto del contenido no coincide con la query.
- Cobertura del corpus: algunas películas mencionadas en las queries o el historial (por ejemplo, "El hombre invisible" para Valentina) no se encuentran en la base de datos, lo que limita el techo de calidad alcanzable independientemente del modelo.

6. Mejoras sugeridas

- Enriquecer el corpus con el resumen de reseñas de usuarios que provee IMDb, para capturar atributos hoy no evaluables (calidad percibida, ritmo, estilo).
- Reemplazar la clasificación discreta del LLM por una asignación continua de pesos a query e historial, en lugar de un mapeo fijo por categoría — sujeto a un análisis de costo/beneficio frente a la pérdida de interpretabilidad y reproducibilidad que esto implica.
- Usar el LLM para reformular la query hacia un estilo más cercano al de una sinopsis (mencionando géneros explícitos), lo que beneficiaría en particular al Enfoque 3, donde las queries "normales" sin vocabulario de género quedan en desventaja frente a sinopsis que sí lo mencionan.
- Incorporar una segunda fuente de verdad para la evaluación (por ejemplo, un panel de evaluadores humanos sobre una muestra) que no dependa exclusivamente del género, para confirmar o refutar las señales de desconexión métrica-calidad observadas en este informe.

7. Conclusión

Ningún enfoque alcanzó un desempeño absoluto satisfactorio, ni en las métricas cuantitativas ni — sobre todo — en la revisión manual caso por caso. El Enfoque 1 (embeddings sin ponderar) obtuvo las mejores métricas agregadas, pero el Enfoque 2 (embeddings + LLM)

mostró mayor coherencia cualitativa en los casos donde separar query e historial evita que uno opaque al otro, particularmente en los perfiles ambiguos. El Enfoque 3 (TF-IDF + LLM) quedó en un punto intermedio, validando que una representación léxica simple puede ser competitiva cuando el vocabulario de la query coincide con el de las sinopsis, aunque sin la capacidad de generalización semántica de los embeddings.

La recomendación para una eventual puesta en producción no es simplemente "elegir el enfoque con mayor F1": dado que la métrica disponible es un proxy imperfecto, conviene priorizar el enfoque que ofrezca mayor coherencia cualitativa y mejor manejo de los casos ambiguos — en este análisis, el Enfoque 2 — y acompañar cualquier decisión con una validación humana adicional antes de confiar en las métricas de género de forma aislada. La dificultad central de este problema no está tanto en la elección del modelo de representación, sino en la escasez de información estructurada sobre las películas y en la falta de una métrica de evaluación que no dependa de un proxy imperfecto como el género.