

Trabajo Final Integrador
Introducción al Procesamiento de Lenguaje Natural

Sistema de Recomendación de Películas basado en NLP

Nazareno Magallanes

Agustín Sigales

Belén Quiñones

1er Cuatrimestre 2026

1. Introducción

El presente trabajo implementa un **sistema de recomendación de películas basado en contenido** utilizando técnicas de Procesamiento de Lenguaje Natural. El sistema opera sobre el corpus [mathigatti/spanish imdb synopsis](#), que contiene aproximadamente 4.970 películas con sinopsis en español, keywords, género, año y director, proveniente de HuggingFace.

El objetivo es generar, para cada uno de los 14 perfiles de usuario simulados, una lista de **5 películas recomendadas**. Cada perfil incluye un historial de 5 películas vistas y una query en lenguaje natural que expresa la intención de búsqueda.

Se implementaron y compararon **tres estrategias de representación**:

- **Embeddings con Sentence Transformer (ST)**: concatenación de query e historial en un único vector.
- **Embeddings promediados con clasificación por LLM (ST+LLM)**: separación de señales y combinación ponderada dinámica.
- **Topic Modeling con BERTopic (TM)**: representación de películas y usuarios mediante distribuciones de tópicos.

2. Datos

2.1. Corpus de películas

El dataset contiene 4.969 películas con los campos: **name**, **description**, **director**, **year**, **genre** y **keywords**. Una limitación notable es que los campos *genre* y *keywords* presentan mezcla de inglés y español, lo que constituye una limitación del corpus. El modelo multilingüe utilizado es suficientemente robusto para manejar esta situación, aunque vale la pena señalar esta limitación.

2.2. Perfiles de usuario

Se trabajó con 14 usuarios simulados, clasificados en dos grupos: **9 usuarios con perfiles definidos** (preferencias claras y consistentes en su historial y query) y **5 usuarios ambiguos** (U10–U14), cuyas consultas son vagas o contradictorias. La evaluación cuantitativa se restringe a los 9 perfiles definidos.

2.3. Preprocesamiento

Antes de cualquier procesamiento se aplicaron dos correcciones al corpus crudo:

- **Entidades HTML**: algunos campos contenían secuencias como `'` en lugar de los caracteres reales. Se aplicó `html.unescape()` sobre todas las columnas de tipo texto.
- **Identificador único**: el corpus no incluye un campo `id`, por lo que se añadió uno basado en el índice. Aunque nunca fueron utilizados ya que el dataset de usuarios tampoco lo incluye en el historial.

Para la construcción del texto representativo de cada película se unificaron todos los campos disponibles en una única cadena con la estructura:

```
nombre. descripción director. año. género. keywords
```

A cada campo se le aplicó un pipeline de limpieza: remoción de etiquetas HTML residuales, eliminación de caracteres no alfanuméricos (salvo puntuación básica y caracteres españoles) y normalización de espacios múltiples.

3. Enfoques de recomendación

3.1. Enfoque 1 — Embeddings con Sentence Transformer

Modelo

Se utilizó `paraphrase-multilingual-MiniLM-L12-v2`, un Sentence Transformer multilingüe que proyecta textos a un espacio vectorial denso de 384 dimensiones. El modelo tiene un límite de 512 tokens; dado que el texto máximo del corpus tiene ≈ 78 palabras por película (y aproximadamente 1.5–2 tokens por palabra), el truncamiento no representa un riesgo práctico.

Representación de películas

Cada película se codifica como el embedding del texto unificado descrito en la sección 2.3. Los embeddings se calculan con `model.encode()` sobre el listado completo del corpus.

Representación de usuarios

Para cada usuario se construye un único texto concatenando la query con el texto unificado de las 5 películas de su historial. Este texto combinado se proyecta con el mismo modelo, de modo que query e historial pesan conjuntamente dentro de un solo vector.

Recomendaciones

Se calcula la **similitud coseno** entre el vector del usuario y todos los vectores de películas. Las películas ya vistas se filtran asignándoles un score de $-\infty$ para que no aparezcan entre las recomendadas. Se devuelve el **top-5** por puntaje.

3.2. Enfoque 2 — Embeddings promediados + LLM (ST+LLM)

El Enfoque 1 no permite regular el peso relativo de la query versus el historial. Este enfoque los **separa** y los combina con un **promedio ponderado dinámico**, donde los pesos son determinados por la **intención de la query** según la clasifica un LLM local.

Clasificación de intención con Ollama (llama3.2)

Cada query se clasifica en una de tres categorías mediante un prompt estructurado enviado al modelo `llama3.2` (temperatura=0.1, seed fijo para reproducibilidad):

Categoría	Descripción	Pesos [query, hist.]	Dirección
normal	Query específica, sin referencia al historial	[0.7, 0.3]	top-5
historial_positivo	El usuario quiere "lo de siempre" o la query es muy vaga	[0.1, 0.9]	top-5
historial_negativo	El usuario pide algo distinto a sus gustos habituales	[0.1, 0.9]	bottom-5

Construcción del embedding de usuario

Se calculan por separado: (a) el embedding de la **query** del usuario y (b) el **embedding promedio** de los vectores de sus 5 películas del historial. Luego se combinan mediante `np.average(..., weights=[w_query, w_hist])`, donde los pesos provienen de la clasificación del LLM.

Para la categoría **historial_negativo**, en lugar de devolver el top-5 más similar, se devuelve el **bottom-5** (las películas menos similares al perfil del usuario), buscando recomendaciones que rompan sus patrones habituales.

Observaciones sobre la clasificación

La clasificación resultó coherente en la mayoría de los casos: la mayor parte de las queries cayeron en **normal** (U01, U03, U05–U11, U13), dos en **historial_positivo** (U02, U04 — queries más vagas) y uno en **historial_negativo** (U12, que explícitamente pide "algo distinto a lo de siempre"). Se observaron algunas asignaciones discutibles (U02 y U04 podrían considerarse *normal*), lo que evidencia que el LLM puede fallar en algunos casos, afectando drásticamente los pesos y la dirección de la búsqueda.

3.3. Enfoque 3 — Topic Modeling con BERTopic

Este enfoque es conceptualmente distinto: en vez de comparar embeddings densos, **descubre tópicos latentes** en el corpus y representa tanto películas como usuarios mediante **distribuciones de probabilidad** sobre esos tópicos.

Entrenamiento del modelo

Se instanció BERTopic con configuración mínima (componentes por defecto, `calculate_probabilities=True`), pasándole los embeddings precomputados con Sentence Transformer y la misma instancia del modelo (`embedding_model=model`). El entrenamiento devuelve una asignación de tópico y una distribución de probabilidad para cada película del corpus.

Representación de usuarios

Para cada usuario se construye un texto concatenando su query con el texto de las 5 películas de su historial. Se aplica `topic_model.transform()` de forma vectorizada sobre todos los usuarios, obteniendo su distribución sobre los tópicos. La recomendación se realiza calculando **similitud coseno** entre distribuciones de usuario y películas, filtrando las películas presentes en el historial.

4. Evaluación

4.1. Metodología

La ausencia de etiquetas de relevancia explícitas obliga a usar el **género** como aproximación. Para cada uno de los 9 usuarios con perfil definido se asignaron manualmente **3 géneros esperados**, inferidos a partir del historial y la query. Sobre esa base se calcularon:

- **Recall (géneros):** proporción de géneros esperados que aparecen en alguna película del top-5.
- **Precisión (películas):** proporción de películas del top-5 que contienen al menos un género esperado.
- **F1-Score:** media armónica de recall y precisión.

Los 5 usuarios ambiguos (U10–U14) quedan fuera de la evaluación cuantitativa porque no es posible asignarles géneros esperados de forma confiable.

4.2. Limitaciones de la evaluación

Las métricas deben interpretarse con cautela. Se observaron casos de **métricas perfectas con recomendaciones cualitativamente incorrectas**: Camila alcanza F1=100% en el Enfoque 1 porque toda su query y su historial son consistentes con el género comedia, pero ninguna película recomendada cumple el requisito específico de "una relación que empiece de forma ridícula o accidental". Esto revela que las métricas basadas en género son permisivas y no capturan la intención granular de las queries.

Otras limitaciones identificadas: géneros incorrectos o faltantes en el corpus, etiquetado subjetivo de géneros esperados sin consenso, y el hecho de que algunas películas solicitadas directamente simplemente no existen en la base de datos.

4.3. Resultados

A continuación se presentan los resultados comparativos de las métricas obtenidas por cada enfoque sobre los 9 usuarios con perfil definido. Los valores exactos por usuario se encuentran en los archivos `evaluacion_transformer.csv`, `evaluacion_transformer_promedio.csv` y `evaluacion_topic_modeling.csv` generados por el notebook.

Enfoque	Recall promedio	Precision promedio	F1 promedio
ST (Enfoque 1)	88.9%	91.1%	88.8%
ST+LLM (Enfoque 2)	70.4%	82.2%	71.7%
BERTopic (Enfoque 3)	66.7%	75.6%	69.8%

5. Análisis cualitativo por enfoque

5.1. Enfoque 1 — ST

Las recomendaciones son coherentes con los géneros del historial, pero el enfoque tiene limitaciones cuando la query pide algo que no puede inferirse del corpus disponible. Ejemplos representativos:

- **Valentina** (suspense/terror): el sistema no puede encontrar la película específica solicitada (*El hombre invisible*) porque no está en la base de datos. Aun así, recomendaciones como *La Mano Que Mece La Cuna* y *Truly Madly Deeply* se acercan temáticamente.
- **Mariana** (ambigua): pide algo *distinto* a lo de siempre, pero el sistema siempre maximiza similitud con su historial. Este es el caso más claro de limitación del Enfoque 1.
- **Nicolás** (ambiguo): pide una película que no sea muy larga y se le recomienda *Titanic* (3h30m), ya que la duración no está disponible en el corpus.

5.2. Enfoque 2 — ST+LLM

La clasificación con el LLM resuelve el caso de Mariana (U12 → *historial_negativo* → bottom-5) y modula la influencia del historial para queries vagas. Sin embargo, las métricas globales cayeron respecto al Enfoque 1, en parte por clasificaciones de frontera incorrectas (p. ej. Rodrigo clasificado como *historial_positivo* cuando su query es bastante específica).

Ejemplo positivo: Valentina mejora notablemente. El sistema recomienda *El ente* (1983), que cumple casi a la perfección con su query (mujer atacada por una presencia invisible).

5.3. Enfoque 3 — BERTopic

Los resultados son heterogéneos y el método no generaliza bien al tamaño del corpus (~5.000 documentos). Algunos usuarios (Camila, Martín) alcanzan F1=100% mientras otros (Lucía) obtienen F1=0%, lo que evidencia inestabilidad. El topic modeling tiene mayor sentido con corpus más grandes donde los tópicos latentes son más estables.

6. Limitaciones del sistema

Más allá de las limitaciones específicas de cada enfoque, se identifican las siguientes restricciones estructurales del sistema:

- **Corpus limitado:** el dataset no incluye información sobre duración, idioma, país de origen ni resumen de reseñas del público. Estas variables serían relevantes para queries que mencionan características como "que enganche desde el principio" o "con buenas actuaciones".
- **Historial escaso:** 5 películas por usuario es insuficiente para construir un perfil robusto, especialmente en casos de géneros variados.
- **Pocos usuarios para validación:** 14 usuarios son insuficientes para obtener una validación robusta del sistema.
- **Métricas permisivas:** la evaluación basada en género captura coherencia temática superficial pero no la intención granular de las queries.
- **LLM de frontera:** la calidad del Enfoque 2 depende directamente de que *llama3.2* clasifique correctamente la intención; un error de categoría cambia drásticamente pesos y dirección de búsqueda.

7. Mejoras propuestas

- **Enriquecer el corpus:** agregar el resumen generado a partir de reseñas de IMDb, duración de las películas e información de país/idioma original.
- **LLM más avanzado:** reemplazar *llama3.2* por un modelo más capaz que pueda asignar pesos dinámicos continuos (no solo tres categorías fijas) y razonar sobre matices de las queries.
- **Query augmentation:** usar el LLM para expandir la query del usuario de modo que se asemeje a una sinopsis, mencionando géneros esperados explícitamente antes de calcular el embedding.
- **Composición distinta de BERTopic:** explorar distintas composiciones del modelo podría mejorar su desempeño.

8. Conclusión

Los tres enfoques implementados muestran capacidades distintas frente al problema de recomendación basada en contenido. Los **embeddings densos con Sentence Transformer** ofrecen la representación semántica más robusta para este corpus y tamaño de datos. La incorporación de un **LLM para clasificar la intención de la query** introduce flexibilidad en el manejo de casos extremos (usuarios que quieren algo distinto), aunque la dependencia de una clasificación correcta es un punto de fragilidad. El **topic modeling con BERTopic** resulta poco adecuado para un corpus de ~5.000 documentos, donde la distribución de tópicos no es suficientemente estable.

El desempeño general permanece limitado por la escasez de información en el corpus y la dificultad de evaluar recomendaciones sin *ground truth* explícito. Las mejoras con más impacto vendrían del enriquecimiento del corpus con datos adicionales de IMDb y del uso de modelos de lenguaje más avanzados.