

Sistema de recomendación de películas basado en NLP

Informe técnico de evaluación de modelo

Agustín Sigales

Nazareno Magallanes

Trabajo Final Integrador — Introducción al Procesamiento del Lenguaje Natural

Junio de 2026

1. Resumen

Se diseñó y evaluó un sistema de recomendación de películas basado en contenido, sobre un corpus de aproximadamente 4.970 películas en español (sinopsis, género, año, director y palabras clave) y 14 perfiles de usuario simulados, cada uno con un historial de 5 películas y una consulta ("query") en lenguaje natural. El objetivo fue generar, para cada usuario, una lista de 5 recomendaciones.

Se implementaron y compararon tres enfoques de representación y ponderación, resumidos en la Tabla 1:

- **Enfoque 1 — Embeddings con Sentence-Transformer:** representación semántica de query e historial concatenados en un único vector.
- **Enfoque 2 — Embeddings ponderados con LLM:** separa query e historial, y un LLM clasifica la intención de la consulta para definir cuánto peso darle a cada señal.
- **Enfoque 3 — TF-IDF ponderado con LLM:** misma lógica de ponderación que el Enfoque 2, pero sobre una representación léxica (TF-IDF) en lugar de embeddings semánticos.

Tabla 1. Métricas promedio por enfoque sobre los 9 perfiles con géneros etiquetados. La columna "Exactitud humana" refleja la proporción de recomendaciones del top-5 validadas manualmente como pertinentes.

Enfoque	Recall	Precision	F1	Exactitud Humana
Enfoque 1	88.9%	91.1%	88.8%	35.5%
Enfoque 2	77.8%	82.2%	76.1%	42.2%
Enfoque 3	88.9%	80.0%	83.1%	20.0%

El Enfoque 1 obtuvo las mejores métricas de género (F1 = 88.8%), seguido por el Enfoque 3 (F1 = 83.1%) y el Enfoque 2 (F1 = 76.1%). Sin embargo, la conclusión central de este trabajo es que estas métricas sobreestiman sistemáticamente la calidad real de las recomendaciones. La validación humana confirma y cuantifica esta desconexión: el Enfoque 2 (el de menor F1) obtuvo la mayor exactitud humana (42.2%), mientras que el Enfoque 3 apenas alcanzó el 20.0%. Esta inversión del ranking entre métricas automáticas y validación humana es el hallazgo principal a tener en cuenta antes de llevar cualquiera de estos modelos a producción.

2. Diseño del sistema

2.1 Datos y representación de las películas

Cada película se representó como un único texto que concatena nombre, sinopsis, director, género y palabras clave, tras un pipeline de limpieza (decodificación de entidades HTML, eliminación de caracteres extraños y espacios redundantes). Esta decisión es central: define qué información puede "entender" el sistema por similitud, y excluye de entrada cualquier atributo que el corpus no provee (duración, elenco, calidad de actuación, ritmo narrativo) que varias queries de usuario sí mencionan.

Para los enfoques 2 y 3, la representación de cada usuario combina dos señales por separado: el embedding (o vector TF-IDF) de su query, y el promedio de los embeddings de las 5 películas de su historial. La forma de combinarlas (qué peso le da cada una y en qué dirección buscar) depende de la clasificación de intención descrita en la sección 2.2.

2.2 Clasificación de intención con LLM

Para los enfoques 2 y 3 se utilizó gemini-2.5-flash-lite para clasificar cada query en una de cuatro categorías, cada una con un esquema de pesos y dirección de búsqueda asociado:

- **normal:** la query describe atributos evaluables por el sistema (género, tema, trama). Se prioriza la query por sobre el historial.
- **historial_positivo:** la query es vaga o pide algo similar a lo habitual. Se prioriza el historial.
- **historial_negativo:** la query pide explícitamente algo distinto a lo habitual. Se prioriza el historial, pero se buscan las películas menos similares.
- **no_evaluable:** la query depende de atributos que el sistema no puede medir (calidad de actuación, duración, etc.). Se trata como historial_positivo, pero se mantiene como categoría separada para cuantificar esta limitación del sistema.

La clasificación resultó, en general, coherente con la redacción de las queries, incluyendo casos de frontera no triviales: una query como "quiero algo distinto a lo de siempre, pero tampoco tan raro" fue correctamente identificada como historial_negativo, y queries que combinan un pedido específico con un atributo no evaluable (por ejemplo, mencionar "estilo visual" dentro de una consulta por lo demás concreta) fueron clasificadas como normal cuando el resto de la query aportaba suficiente señal evaluable. La calidad de este enfoque depende críticamente de que la clasificación sea correcta: un error de categoría cambia drásticamente los pesos y hasta la dirección de búsqueda.

2.3 Métrica de evaluación

No existe en el corpus un listado de "películas correctas" por usuario, por lo que se utilizó el género como aproximación de relevancia. Para los 9 perfiles de usuario con preferencias claras y consistentes, se etiquetaron a mano 3 géneros esperados por usuario, a partir de su historial y su query. Sobre esa base se calculó, por usuario:

- **Recall:** proporción de géneros esperados que aparecen en el top-5 recomendado.
- **Precision:** proporción de películas del top-5 que tienen al menos un género esperado.

- **F1:** media armónica de ambas.

Los 5 perfiles restantes (difíciles de clasificar o ambiguos) no se incluyeron en la evaluación cuantitativa por no admitir un etiquetado confiable, pero sí se usaron para el análisis cualitativo, ya que son los casos donde la ponderación dinámica de los enfoques 2 y 3 muestra su mayor potencial.

Adicionalmente, se incorporó una **validación humana parcial**: para los mismos 9 perfiles definidos, un evaluador revisó el top-5 de cada enfoque y determinó cuántas recomendaciones consideraba genuinamente adecuadas para la query del usuario, independientemente del género. Esta métrica complementa a las automáticas al no depender del género como proxy.

3. Resultados por enfoque

3.1 Enfoque 1 — Embeddings con Sentence-Transformer

Este enfoque concatena query e historial en un único texto y lo proyecta con el modelo multilingüe *paraphrase-multilingual-MiniLM-L12-v2*, recomendando por similitud coseno contra el espacio de películas.

Tabla 2. Top-5 de recomendaciones por usuario — Enfoque 1.

Usuario	#1	#2	#3	#4	#5
Valentina	Tránsito (2006)	La mano que mece la cuna (1992)	Begotten (1991)	Truly Madly Deeply (1992)	La novia cadáver (2005)
Rodrigo	Historia de un soldado (1985)	Monster's Ball (2002)	Vida de este chico (1994)	Una árida estación blanca (1989)	Gorilas en la niebla (1989)
Camila	Ahora los padres son ellos (2010)	Mira quién habla también (1991)	Más allá del odio (2005)	Swingers (1997)	La familia Addams (1992)
Tomás	La red (1995)	Pulse (Conexión) (2007)	El cortador de césped (1992)	Nivel 13 (1999)	Proyecto Brainstorm (1983)
Lucía	Tránsito (2006)	Begotten (1991)	Durmiendo con su enemigo (1991)	La mano que mece la cuna (1992)	Crónica de un engaño (2010)
Martín	Como pez en el agua (1998)	El negociador (1997)	Persecución extrema (2007)	Albino Alligator (1997)	¡Que te calles! (2004)
Sofía	Ray (2005)	Hedwig and the Angry Inch (2001)	La diva (1981)	Miedo y asco en Las Vegas (1999)	El corazón del ángel (1987)
Diego	Hollywood: Departamento de homicidios (2003)	Más fuerte que el odio (1988)	The Fast and the Furious (A todo gas) (2001)	Max Payne (2008)	L.A. Confidential (1997)

Usuario	#1	#2	#3	#4	#5
Elena	Brothers (Hermanos) (2010)	Algo en común (2005)	El turista accidental (1989)	Todos están bien (2010)	La vida de Pi (2012)
Facundo	Apocalipsis (1994)	Seul contre tous (1999)	Atando cabos (2002)	La última casa a la izquierda (2009)	Aún sé lo que hicisteis el último verano (1999)
Julián	Prince of Persia: Las arenas del tiempo (2010)	La bella y la bestia (1992)	La princesa cisne (1995)	El emperador y sus locuras (2001)	Salvaje (The Wild) (2006)
Mariana	Juana de Arco de Luc Besson (2000)	El marido de la peluquera (1990)	Ángel (2007)	Belleza robada (1996)	El juego de Ripley (2003)
Nicolás	Titanic - La película animada (2000)	Buscando a Eva (1999)	Pearl Harbor (2001)	La hoguera de las vanidades (1990)	Matador (1986)
Paula	Sabrina (y sus amores) (1996)	Doble cuerpo (1985)	La desaparición de Embry (2004)	Fallen Angels (Ángeles caídos) (1995)	Luz de luna (1986)

Tabla 3. Métricas por usuario — Enfoque 1.

Usuario	Recall	Precision	F1	Val. Humana
Valentina	100.0%	100.0%	100.0%	2/5
Rodrigo	66.7%	60.0%	63.2%	2/5
Camila	100.0%	100.0%	100.0%	0/5
Tomás	100.0%	100.0%	100.0%	2/5
Lucía	33.3%	80.0%	47.1%	0/5
Martín	100.0%	100.0%	100.0%	3/5
Sofía	100.0%	80.0%	88.9%	2/5
Diego	100.0%	100.0%	100.0%	3/5
Elena	100.0%	100.0%	100.0%	2/5
Promedio	88.9%	91.1%	88.8%	35.5%

Es el enfoque con mejores métricas agregadas, pero también el que mejor ilustra su propia limitación: usuarios con F1 del 100% recibieron recomendaciones que no cumplen la query en términos de trama. El caso de Camila es representativo, las 5 recomendaciones son comedias (cumpliendo el género explícito de la query), pero ninguna cumple con la situación particular que pide ("una relación que empieza de forma ridícula o accidental"). El sistema captura el género porque está mencionado explícitamente, pero no tiene forma de verificar la trama específica más allá de la similitud textual general. Otro patrón recurrente es que, al mezclar query e historial en un solo vector, una query con poco contenido propio (como la de un usuario

que pide "algo distinto" a su historial) termina dominada por el historial, contradiciendo la intención real del pedido.

La validación humana revela esta limitación con números concretos: exactitud del 35.5% (16/45). Camila y Lucía obtienen 0/5, evidenciando que su F1 perfecto en métricas automáticas es completamente engañoso. Martín y Diego son los más beneficiados (3/5 cada uno), lo que coincide con perfiles cuyas queries tienen vocabulario explícito de género directamente evaluable.

3.2 Enfoque 2 — Embeddings ponderados con LLM

Separa el embedding de la query del embedding del historial (promedio de las 5 películas vistas) y los combina con un promedio ponderado según la categoría asignada por el LLM.

Tabla 4. Top-5 de recomendaciones por usuario — Enfoque 2.

Usuario	#1	#2	#3	#4	#5
Valentina	El ente (1983)	Tránsito (2006)	Femme Fatale (2003)	Alone in the Dark (2006)	The Ring (La señal) (2003)
Rodrigo	Enemigo público (1999)	El asesinato de Richard Nixon (2006)	La noche cae sobre Manhattan (1997)	Dark Blue (2004)	Sospechoso (1988)
Camila	Escuela de novatos (2004)	La pareja basura (1991)	Misterioso asesinato en Manhattan (1994)	La comedia sexual de una noche de verano (1982)	Ensalada de gemelas (1988)
Tomás	Proyecto Brainstorm (1983)	Pequeños guerreros (1998)	El asesinato de Richard Nixon (2006)	Paycheck (2004)	La gran huida (1984)
Lucía	Daredevil (2003)	Virtuosity (1995)	Número 9 (2010)	Code Geass: Lelouch of the Rebellion (2006)	Cuentos de Terramar (2006)
Martín	Plan oculto (2006)	Supercañeras: El internado puede ser una fiesta (2002)	Sin motivo aparente (2003)	Albino Alligator (1997)	Heat (1996)
Sofía	Aquarius (1987)	Once (2007)	Ragtime (1982)	El vagón de la muerte (2008)	Slacker (1991)
Diego	El único (2002)	The Punisher (El castigador) (2004)	El coche fantástico (N/A)	Snake Eyes (Ojos de serpiente) (1998)	Una historia de violencia (2005)
Elena	El orfanato (2007)	A la deriva (2006)	Red Rock West (1995)	Reeker (2006)	La tostadora valiente (1994)
Facundo	Inland Empire (2007)	El bosque (2004)	Misteriosa obsesión (2004)	La trama (1998)	Proyecto Brainstorm (1983)
Julián	El último gran héroe (1993)	La bella y la bestia (1992)	Agárralo como puedas (1989)	El último golpe (2003)	La noche del duende (1993)

Usuario	#1	#2	#3	#4	#5
Mariana	Top Chef (2006)	Frasier (1993)	Un entrenador de primera (1996)	Cory en la Casa Blanca (2007)	Super Size Me (2004)
Nicolas	El último golpe (2003)	Razas de noche (1990)	El último gran héroe (1993)	Sé lo que hicisteis el último verano (1998)	13 (2020)
Paula	Nowhere (1997)	Memorias de un hombre invisible (1993)	Three (2006)	Amor loco (1995)	Cueste lo que cueste (2000)

Tabla 5. Métricas por usuario — Enfoque 2.

Usuario	Recall	Precision	F1	Val. Humana
Valentina	100.0%	100.0%	100.0%	3/5
Rodrigo	66.7%	80.0%	72.7%	3/5
Camila	33.3%	100.0%	50.0%	2/5
Tomás	100.0%	80.0%	88.9%	1/5
Lucía	100.0%	60.0%	75.0%	1/5
Martín	100.0%	100.0%	100.0%	4/5
Sofía	100.0%	60.0%	75.0%	2/5
Diego	66.7%	100.0%	80.0%	3/5
Elena	33.3%	60.0%	42.9%	0/5
Promedio	77.8%	82.2%	76.1%	42.2%

Las tres métricas cayeron respecto al Enfoque 1. Sin embargo, la inspección manual matiza esta caída: para Valentina, la recomendación de mayor score ("El ente", 1983) describe casi exactamente la situación de su query (una mujer atacada por una entidad invisible) algo que el Enfoque 1 no había logrado priorizar con tanta claridad. Para Rodrigo, el F1 es menor que en el Enfoque 1, pero todas las películas recomendadas tratan efectivamente sobre corrupción política, mostrando mayor coherencia temática aunque el género formal asignado no siempre coincida con el esperado. Este patrón, caída en la métrica y mejora cualitativa, es el que motiva la advertencia sobre la confiabilidad de la métrica basada en género.

La validación humana confirma y cuantifica esta mejora cualitativa: con una exactitud del 42.2% (19/45), el Enfoque 2 es el mejor de los tres. Martín lidera con 4/5, y Valentina, Rodrigo y Diego obtienen 3/5 cada uno. Elena es la excepción con 0/5, lo que apunta a una interacción problemática entre su perfil y la categorización del LLM. Sobre los perfiles ambiguos, cuando un usuario pide explícitamente algo distinto a su historial, el sistema invierte correctamente la dirección de búsqueda, falla que el Enfoque 1 no podía corregir.

3.3 Enfoque 3 — TF-IDF ponderado con LLM

Aplica la misma lógica de ponderación del Enfoque 2 (separar query e historial, combinar según la clasificación del LLM), pero sobre una representación TF-IDF. Previo a la vectorización se tradujeron al español las palabras clave en inglés y se aplicó *lemmatization*, dado que TF-IDF, a diferencia de los embeddings, trata cada variante léxica como una dimensión independiente sin relación semántica entre sí.

Tabla 6. Top-5 de recomendaciones por usuario — Enfoque 3.

Usuario	#1	#2	#3	#4	#5
Valentina	Inseparables (1989)	Cabin fever 2 (2011)	Los ríos de color púrpura 2: Los ángeles del apocalipsis (2004)	El hombre sin sombra (2000)	Suavemente me mata (2002)
Rodrigo	Maleficio (2006)	El expreso de Elmira (2008)	Buenas noches, y buena suerte. (2006)	El asesinato de Richard Nixon (2006)	Machuca (2004)
Camila	Loverboy (1989)	Padre Made in USA (2005)	Forasteros en Nueva York (1999)	Testigo accidental (1990)	La posesión (1981)
Tomás	Gothika (2004)	Halloweentown: ¡Qué familia la mía! (1998)	Así se hace (2001)	El aceite de la vida (1993)	Joint Security Area (JSA) (2000)
Lucía	V de Vendetta (2006)	Samurai Jack (2017)	Haru en el reino de los gatos (2002)	Cheque en blanco (1994)	Libertad para morir (1991)
Martín	Phantoms (1998)	Los idiotas (1999)	La cena (2010)	Pret-a-porter (1995)	La rebelión de las máquinas (1986)
Sofía	The Shield: Al margen de la ley (2003)	Begotten (1991)	Adiós, muchachos (1989)	Los fabulosos Baker Boys (1990)	El rey de la comedia (1982)
Diego	Las aventuras de Jackie Chan (2000)	Justa venganza (2005)	Pusher 3: Soy el ángel de la muerte (2005)	Air America (1990)	Luna negra (1987)
Elena	Padre Ted (1995)	Algo en común (2005)	Click (2006)	Bienvenido a Mooseport (2004)	South Park (1997)
Facundo	Koyaanisqatsi (1984)	Innocence (2005)	Noviembre dulce (2001)	Lars y una chica de verdad (2008)	Juno (2008)
Julian	Pride & Prejudice (Orgullo y prejuicio) (2006)	El príncipe y yo (2004)	Salvaje (The Wild) (2006)	Los Tommyknockers (1993)	RoboCop 2 (1991)
Mariana	Déjà vu (2006)	Warlock, el brujo (1990)	Fuga mortal (1993)	Ted Bundy (2003)	The Zodiac (2006)

Usuario	#1	#2	#3	#4	#5
Nicolas	El señor de los anillos: El retorno del rey (2...	Kill Bill: Volumen 2 (2004)	El señor de los anillos: Las dos torres (2002)	La leyenda de Billie Jean (1985)	Titanic - La película animada (2000)
Paula	Transformers (1984)	Dragon Ball Z (1989)	Dragon Ball Z (2019)	El último unicornio (1982)	Billy Elliot (Quiero bailar) (2001)

Tabla 7. Métricas por usuario — Enfoque 3.

Usuario	Recall	Precision	F1	Val. Humana
Valentina	100.0%	80.0%	88.9%	1/5
Rodrigo	100.0%	100.0%	100.0%	2/5
Camila	66.7%	80.0%	72.7%	0/5
Tomás	66.7%	40.0%	50.0%	0/5
Lucía	100.0%	60.0%	75.0%	1/5
Martín	66.7%	80.0%	72.7%	0/5
Sofía	100.0%	80.0%	88.9%	1/5
Diego	100.0%	100.0%	100.0%	3/5
Elena	100.0%	100.0%	100.0%	1/5
Promedio	88.9%	80.0%	83.1%	20.0%

El desempeño quedó en un punto intermedio entre los dos enfoques anteriores, mejor de lo esperado para una representación puramente léxica. Esto se explica porque buena parte de las queries comparten vocabulario explícito con las sinopsis del corpus (palabras como "amenaza", "corrupción", "hechos reales" aparecen tanto en la query como en la descripción de la película recomendada), lo que favorece a TF-IDF en pedidos literales. La contracara se observa en los perfiles ambiguos: para usuarios clasificados como no_evaluable, el sistema recurre a coincidencias de historial que en ocasiones son demasiado literales — por ejemplo, recomendar la secuela directa de una película ya vista, o un título con coincidencia parcial de nombre en lugar de una similitud temática real.

La validación humana revela la brecha más pronunciada de los tres enfoques: apenas un 20.0% de exactitud (9/45). Camila, Tomás y Martín obtienen 0/5, mostrando que la coincidencia léxica no captura la intención narrativa de queries más exigentes. Diego es el único con buenos resultados (3/5), lo que sugiere que TF-IDF funciona cuando la query y las sinopsis comparten vocabulario suficiente.

4. Por qué desconfiar de las métricas

El patrón más consistente a lo largo de los tres enfoques es la desconexión entre las métricas cuantitativas y la calidad real evaluada manualmente. Esto tiene una causa estructural: el género se usa simultáneamente como parte de la representación de la película (a través del texto unificado) y como criterio de evaluación, lo cual genera una validación parcialmente circular: un sistema puede acertar el género "porque está mencionado en el texto" sin haber entendido la situación, el tono o la trama que la query realmente describe.

A esto se suma que ninguno de los tres enfoques tiene acceso a información que varias queries piden de forma explícita: duración ("que no sea muy larga"), calidad de actuación, ritmo narrativo o estilo visual. Para cuantificar esta limitación se introdujo la categoría `no_evaluable` en la clasificación del Enfoque 2, en lugar de ignorarla o forzarla a encajar en otra categoría.

La validación humana aporta evidencia cuantitativa directa sobre esta desconexión: el Enfoque 2 invierte su posición en el ranking al pasar de métricas de género a exactitud humana (de tercero a primero), y el Enfoque 3 hace lo opuesto (de primero empatado a tercero). En conjunto, estos factores (circularidad de la métrica, ausencia de atributos relevantes en el corpus, y la inversión de ranking confirmada por la evaluación humana) explican mejor las diferencias de desempeño que la elección del modelo de representación en sí.

La validación humana también debe interpretarse con cautela. La muestra es de tan solo 9 usuarios y la evaluación fue realizada por un único evaluador, lo que introduce sesgo y alta varianza: basta con que un usuario cambie una puntuación para que la exactitud global se mueva varios puntos porcentuales.

5. Limitaciones

- **Dataset pequeño con historial escaso:** 14 usuarios con 5 películas cada uno es insuficiente para una validación estadísticamente robusta.
- **Etiquetado subjetivo:** los géneros esperados por usuario se asignaron manualmente, sin un segundo evaluador ni consenso.
- **Géneros del corpus potencialmente incorrectos o incompletos:** se observaron algunos casos de películas con géneros mal asignados o géneros temáticamente relevantes ausentes.
- **Métricas permisivas:** una película con un solo género esperado en común ya se considera "correcta" en el cálculo, aun si el resto del contenido no coincide con la query.
- **Cobertura del corpus:** algunas películas mencionadas en las queries o el historial (por ejemplo, "El hombre invisible" para Valentina) no se encuentran en la base de datos, lo que limita el techo de calidad alcanzable independientemente del modelo.

6. Mejoras sugeridas

- Enriquecer el corpus con el resumen de reseñas de usuarios que provee IMDb, para capturar atributos hoy no evaluables (calidad percibida, ritmo, estilo).

- Reemplazar la clasificación discreta del LLM por una asignación continua de pesos a query e historial, en lugar de un mapeo fijo por categoría.
- Usar el LLM para reformular la query hacia un estilo más cercano al de una sinopsis (mencionando géneros explícitos), lo que beneficiaría en particular al Enfoque 3, donde las queries "normales" sin vocabulario de género quedan en desventaja frente a sinopsis que sí lo mencionan.
- Incorporar una validación humana a mayor escala, con múltiples evaluadores y un protocolo de consenso, para obtener una métrica de exactitud estadísticamente más sólida que la presentada en este trabajo y que pueda informar con mayor seguridad la elección de enfoque para producción.

7. Conclusión

Ningún enfoque alcanzó un desempeño absoluto satisfactorio, ni en las métricas cuantitativas ni en la revisión manual caso por caso. El Enfoque 1 (embeddings sin ponderar) obtuvo las mejores métricas de género, pero el Enfoque 2 (embeddings + LLM) mostró mayor coherencia cualitativa en los casos donde separar query e historial evita que uno opaque al otro, particularmente en los perfiles ambiguos y esta superioridad se confirma con la validación humana (42.2% vs. 35.5% vs. 20.0%). El Enfoque 3 (TF-IDF + LLM) quedó en un punto intermedio en métricas de género, pero la validación humana revela que esta competitividad no se traduce en mejor calidad real: con apenas un 20.0% de exactitud, queda muy por detrás del Enfoque 2 pese a sus métricas automáticas comparables al Enfoque 1.

La recomendación para una eventual puesta en producción no es simplemente "elegir el enfoque con mayor F1": dado que la métrica disponible es un proxy imperfecto, conviene priorizar el enfoque que ofrezca mayor coherencia cualitativa y mejor manejo de los casos ambiguos. En este análisis, ese enfoque es el Enfoque 2. Cualquier decisión debería acompañarse de una validación humana adicional y a mayor escala antes de confiar en las métricas de género de forma aislada. La dificultad central de este problema no está tanto en la elección del modelo de representación, sino en la escasez de información estructurada sobre las películas y en la ausencia de una métrica de evaluación que no dependa de un proxy imperfecto como el género.