

Sistema de Recomendación de Películas basado en NLP

Comparación de tres estrategias de representación de contenido:
Sentence-Transformer · Embeddings promediados + LLM · Topic Modeling
(BERTopic)

1. Introducción y objetivo

Se dispone del corpus **mathigatti/spanish_imdb_synopsis** (~4.970 películas con sinopsis en español, keywords, género, año y director). Se provee además un archivo CSV con 14 perfiles de usuario simulados, cada uno con un historial de 5 películas vistas y una query en lenguaje natural que expresa qué quiere ver a continuación. Los perfiles varían en cohesión: algunos tienen preferencias claras y consistentes (*perfiles definidos*) y otros presentan historiales dispersos y queries poco específicas (*perfiles ambiguos*).

El objetivo es construir un **sistema de recomendación basado en contenido** que, para cada usuario, devuelva una lista de 5 películas relevantes. La decisión metodológica central es cómo representar el contenido y cómo modelar al usuario. Se implementaron y compararon tres enfoques distintos, evaluados con una métrica proxy basada en solapamiento de géneros sobre los 9 perfiles definidos.

2. Corpus y preprocesamiento

2.1. Información disponible

Cada película dispone de seis campos: **nombre, descripción (sinopsis), director, año, género y keywords**. No todos aportan lo mismo. La sinopsis y las keywords concentran el núcleo del contenido, mientras que director, año y género agregan contexto que los usuarios suelen mencionar explícitamente en sus queries ('una de los 90', 'una de Tarantino', 'una comedia'). Por eso se construyó el texto de cada película concatenando los seis campos en un único string, que es la entrada común a los tres enfoques:

```
texto = nombre + ". " + sinopsis + " " + director + ". " + año + ". " + género + ".  
" + keywords
```

La distribución de géneros está fuertemente desbalanceada: drama (2.649), comedia (1.932), acción (1.222) y crimen (1.083) dominan el corpus. Esto sesga al sistema hacia géneros mayoritarios y dificulta recomendar bien a usuarios con gustos de nicho.

2.2. Limpieza y limitaciones

Se aplicó un pipeline de limpieza sobre todas las columnas de texto:

- **Decodificación de entidades HTML:** algunos campos contenían secuencias como ' en lugar de los caracteres reales. Se aplicó `html.unescape` sobre todas las columnas de tipo objeto.
- **Remoción de etiquetas y caracteres extraños:** se eliminaron tags HTML residuales y caracteres no alfanuméricos (excepto puntuación estándar y tildes).
- **Normalización de espacios:** se colapsaron espacios múltiples y se eliminaron espacios al inicio y al final.

Se detectaron dos limitaciones estructurales del corpus:

- **Spanglish en keywords/genre:** muchas keywords mezclan español e inglés dentro del mismo string. El modelo multilingüe es robusto a esto, pero fue entrenado principalmente con texto monolingüe, por lo que la mezcla degrada levemente la representación.

- **Historial incompleto:** para algunos usuarios, una o más películas del historial no aparecen en el corpus con el nombre exacto indicado, por lo que sus sinopsis no se pueden recuperar. Esto reduce la calidad del vector de historial en el Enfoque 2.

3. Modelado del usuario

Un usuario se describe con dos fuentes de información: su **historial** (lo que suele ver, señal estable de preferencias de fondo) y su **query** (lo que quiere ver ahora, puntual y potencialmente diferente al historial). El problema central es cómo combinarlas, sobre todo cuando apuntan en direcciones distintas. Cada enfoque resuelve esto de una forma diferente, y esa es la principal diferencia conceptual entre ellos.

4. Enfoque 1 — Embeddings con Sentence-Transformer

4.1. Descripción

Se utilizó el modelo multilingüe **paraphrase-multilingual-MiniLM-L12-v2** (vectores de 384 dimensiones), que proyecta cualquier texto a un espacio donde los textos semánticamente similares quedan cerca. El modelo devuelve directamente un vector por documento, sin necesidad de promediar embeddings de palabras.

Cada película se representa con el embedding de su texto unificado. Cada usuario se representa **concatenando su query con las sinopsis de las 5 películas de su historial** en un único texto, que se proyecta con el mismo modelo:

```
user_text = query + sinopsis_peli_1 + sinopsis_peli_2 + ... + sinopsis_peli_5
```

Se verificó que la longitud (mediana de 45 palabras por sinopsis, 15,5 por query) queda holgadamente por debajo del límite de 512 tokens del modelo. La recomendación se obtiene por similitud coseno entre el vector del usuario y el de todas las películas: se filtran las ya vistas ($\text{score} = -\infty$) y se devuelve el top-5.

4.2. Ventajas y limitaciones

- **Simple y sin pasos intermedios:** una sola pasada del modelo representa toda la información del usuario. No se requieren decisiones sobre ponderación.
- **Sin control sobre pesos:** al concatenar todo en un único texto, query e historial compiten implícitamente por peso dentro del vector. No hay forma de regular cuánta importancia recibe cada uno.
- **Opacidad:** si la recomendación falla, no es fácil saber si el problema está en la query, en el historial o en la interacción entre ambos.

4.3. Resultados

Este fue el enfoque con mejor desempeño general. Los resultados por usuario sobre los 9 perfiles definidos fueron:

Usuario	Perfil	Recall	Precision	F1
---------	--------	--------	-----------	----

Valentina	definido	100%	100%	100%
Rodrigo	definido	66.7%	60%	63.2%
Camila	definido	100%	100%	100%
Tomás	definido	100%	100%	100%
Lucía	definido	33.3%	80%	47.1%
Martín	definido	100%	100%	100%
Sofía	definido	100%	80%	88.9%
Diego	definido	100%	100%	100%
Elena	definido	100%	100%	100%
PROMEDIO	—	88.9%	91.1%	88.8%

Tabla 1. Métricas por usuario — Enfoque 1.

El caso de acierto más claro es **Diego** (acción directa con un héroe que trabaja solo contra una organización criminal): el sistema recomendó Hollywood: Departamento de homicidios, Max Payne, L.A. Confidential y The Fast and the Furious, todas de acción/crimen con scores altos (0.70-0.79).

El caso más problemático es **Lucía** (animación donde el protagonista lucha por su libertad o identidad): el sistema devolvió Tránsito, Begotten y Durmiendo con su enemigo (drama/terror), sin una sola película de animación. El motivo es que los conceptos abstractos de la query (libertad, identidad, opresión) dominan sobre la palabra animación, y el modelo prioriza el tono existencial por encima del formato.

5. Enfoque 2 — Embeddings promediados + LLM (Ollama)

5.1. Descripción

Este enfoque ataca la limitación del Enfoque 1: separa query e historial y los combina con un **promedio ponderado explícito**, donde los pesos dependen de la intención de la query. Para inferir esa intención se usa un LLM local (**llama3.2** vía Ollama) que clasifica cada query en una de tres categorías:

- **normal**: query específica que no apela al historial → pesos [0.7, 0.3] (más query) y top-5 más similares.
- **historial_positivo**: el usuario quiere 'lo de siempre' o la query es tan vaga que el historial es la mejor guía → pesos [0.1, 0.9] y top-5 más similares.
- **historial_negativo**: el usuario pide algo distinto a lo habitual → pesos [0.1, 0.9] pero eligiendo el *bottom-5* (películas menos similares al perfil).

El pipeline fue el siguiente:

- Calcular el embedding de cada query.
- Calcular el embedding del historial (promedio de los embeddings de las 5 películas vistas).
- Clasificar la intención de la query con Ollama (prompt con salida JSON, temperature=0.1, seed fijo para reproducibilidad).

- Combinar query e historial con np.average ponderado según la clasificación.
- Recomendar por similitud coseno (top-5 o bottom-5 según la dirección).

5.2. Clasificación del LLM

La clasificación fue coherente con la redacción de las queries:

- La mayoría (U1, U3, U5, U6, U7, U8, U9, U10, U11, U13) cayó en **normal** por describir explícitamente género, trama o atmósfera.
- **historial_positivo** apareció en U2 ('algo basado en hechos reales...'), U4 ('algo que haga pensar...') y U14 ('algo intermedio'), donde el historial es mejor guía.
- **historial_negativo** solo en U12 ('quiero algo distinto a lo de siempre...'), el único caso que justifica buscar en la dirección opuesta.

Algunas asignaciones son discutibles en la frontera, lo que muestra que el enfoque hereda los errores del clasificador: una categoría equivocada altera drásticamente los pesos y la dirección de búsqueda.

5.3. Resultados

Usuario	Categoría LLM	Pesos	Recall	Precision	F1
Valentina	normal	[0.7, 0.3]	100%	80%	88.9%
Rodrigo	historial_pos.	[0.1, 0.9]	33.3%	80%	47.1%
Camila	normal	[0.7, 0.3]	33.3%	100%	50.0%
Tomás	historial_pos.	[0.1, 0.9]	66.7%	80%	72.7%
Lucía	normal	[0.7, 0.3]	100%	60%	75.0%
Martín	normal	[0.7, 0.3]	100%	100%	100.0%
Sofía	normal	[0.7, 0.3]	100%	80%	88.9%
Diego	normal	[0.7, 0.3]	66.7%	100%	80.0%
Elena	normal	[0.7, 0.3]	33.3%	60%	42.9%
PROMEDIO	—	—	70.4%	82.2%	71.7%

Tabla 2. Métricas por usuario — Enfoque 2.

El promedio ponderado + LLM fue más débil que el Enfoque 1 (F1 71.7% vs 88.8%). Dos factores lo explican: primero, cuando el historial tiene películas faltantes, promediar menos de 5 embeddings introduce ruido. Segundo, la dirección *bottom-5* para historial_negativo es agresiva y puede traer películas completamente irrelevantes.

6. Enfoque 3 — Topic Modeling con BERTopic

6.1. Descripción

El tercer enfoque es conceptualmente distinto: en lugar de comparar embeddings densos, **descubre tópicos latentes** en el corpus mediante BERTopic (reducción de dimensionalidad UMAP + clustering HDBSCAN sobre los mismos embeddings del Enfoque 1) y representa cada película por su **distribución de probabilidad sobre esos tópicos**.

El usuario se representa igual —proyectando su texto query+historial al espacio de tópicos— y se recomienda por similitud coseno entre distribuciones de tópicos.

BERTopic encontró **70 tópicos interpretables**, por ejemplo:

- Ciencia ficción / alienígenas
- Guerra / Vietnam / bélico
- Detective / policía / asesinato
- Romance / matrimonio

Sin embargo, **2.725 de las ~4.970 películas** (más de la mitad) quedaron asignadas al tópico outlier (–1), lo que limita fuertemente la capacidad discriminativa del sistema.

6.2. Ventajas y problemas

- **Interpretabilidad:** cada tópico tiene palabras representativas que explican por qué se agrupan las películas. Es el enfoque más explicable.
- **Alta proporción de outliers:** más de la mitad del corpus sin tópico asignado. Cuando el perfil de usuario cae cerca del outlier, múltiples películas empatan en similitud 1.0 y la recomendación es arbitraria.
- **Representación binaria en la práctica:** la distribución de tópicos es muy dispersa; los vectores resultantes tienen poca variabilidad, generando empates frecuentes.

6.3. Resultados

Usuario	Recall	Precision	F1	Películas Malas
Valentina	66.7%	100%	80.0%	0
Rodrigo	33.3%	20%	25.0%	4
Camila	100%	100%	100.0%	0
Tomás	66.7%	60%	63.2%	2
Lucía	0.0%	0%	0.0%	5
Martín	100%	100%	100.0%	0
Sofía	66.7%	100%	80.0%	0
Diego	66.7%	100%	80.0%	0
Elena	100%	100%	100.0%	0
PROMEDIO	66.7%	75.6%	69.8%	—

Tabla 3. Métricas por usuario — Enfoque 3.

Los empates de score son críticos: para Rodrigo y Lucía, varias recomendaciones aparecen con similitud 1.0000 (F1 de 25% y 0% respectivamente), confirmando que la representación por tópicos

pierde capacidad de ordenar cuando el perfil cae cerca del outlier.

7. Comparación de los tres enfoques

Enfoque	Recall	Precision	F1
1 — Sentence-Transformer (concatenado)	88.9%	91.1%	88.8%
2 — Promedio ponderado + LLM	70.4%	82.2%	71.7%
3 — Topic Modeling (BERTopic)	66.7%	75.6%	69.8%

Tabla 4. Promedios globales sobre los 9 perfiles definidos.

El resultado más relevante es que **el enfoque más simple obtuvo el mejor desempeño**, superando claramente a los dos más elaborados. Tres factores lo explican:

- El Enfoque 2 introduce un **punto de falla extra** (la clasificación del LLM) y, al promediar embeddings del historial, diluye la señal cuando el historial es disperso o tiene películas faltantes.
- La dirección *bottom-5* del Enfoque 2 para queries de 'cambio' es agresiva y puede traer películas completamente irrelevantes.
- El Enfoque 3 sufre de alta proporción de outliers y representaciones dispersas que generan empates frecuentes, eliminando la capacidad de discriminar entre películas.

8. Limitaciones y evaluación

- **Métrica proxy:** el género no captura matices como 'basado en hechos reales', 'mucha atmósfera' o 'no convencional'. Además solo es válida para los 9 perfiles definidos; los 5 ambiguos (U10–U14) no son evaluables de forma confiable, justamente los casos donde el sistema más podría fallar.
- **Desbalance del corpus:** la dominancia de drama y comedia sesga todas las estrategias hacia esos géneros, lo que perjudica a usuarios con gustos de nicho.
- **Historial incompleto:** algunos nombres de películas en el historial no coinciden exactamente con el corpus, reduciendo la calidad del vector de historial en el Enfoque 2.
- **Sistema puramente basado en contenido:** no considera popularidad, ratings ni comportamiento de otros usuarios. Esto limita estructuralmente las recomendaciones: no podría resolverse con más datos del mismo tipo.
- **Similitud semántica ≠ relevancia para el usuario:** el sistema entiende 'similitud' como cercanía en el espacio vectorial, que no siempre coincide con lo que el usuario entiende como 'relevante'. El caso de Lucía lo ilustra: la query pide animación pero la semántica de la descripción del género domina sobre el nombre del género mismo.

9. Conclusión

Las tres estrategias producen recomendaciones razonables para perfiles con preferencias claras. Sin embargo, los resultados muestran diferencias significativas:

El **Enfoque 1** (concatenación directa con Sentence-Transformer) resultó el más efectivo y robusto, con un F1 promedio de 88.8%. Su simplicidad es una ventaja: al no introducir pasos intermedios, preserva la señal completa del contenido textual y no acumula errores de módulos adicionales.

El **Enfoque 2** (embeddings promediados + LLM) aporta un mecanismo explícito de control sobre cómo se combinan query e historial, lo que es conceptualmente valioso —en particular para queries que piden 'algo distinto'— pero introduce un punto de falla adicional en la clasificación. Con un F1 de 71.7%, la ganancia en interpretabilidad no compensa la pérdida en precisión.

El **Enfoque 3** (BERTopic) ofrece la mejor interpretabilidad del corpus —los tópicos son descriptivos y fácilmente explicables— pero su utilidad para recomendar se ve limitada por la alta proporción de outliers (más del 50% del corpus) que genera empates frecuentes e irreducibles. Con un F1 de 69.8%, es el menos efectivo de los tres.

La principal lección metodológica de este trabajo es que **mayor complejidad no garantiza mejores recomendaciones**: en este corpus y con esta tarea, preservar el contenido textual completo en un único embedding denso fue lo más determinante para la calidad de las recomendaciones.