

Introducción al Procesamiento de Lenguaje Natural

Licenciatura en Ciencia de Datos

Escuela de Ciencia y Tecnología

Universidad Nacional de General San Martín

Primer cuatrimestre 2026

Trabajo Final Integrador

Sistema de Recomendación de Películas basado en NLP

Introducción

Se dispone del corpus [mathigatti/spanish_imdb_synopsis](#), que contiene aproximadamente 4.970 películas con sinopsis en español, keywords, género, año y director. El corpus puede descargarse desde HuggingFace.

Se provee, además, [un archivo .csv con 14 perfiles de usuario simulados](#). Cada perfil contiene un historial de 5 películas vistas y una query en lenguaje natural que expresa lo que el usuario quiere ver a continuación. Los perfiles varían en cohesión: algunos tienen preferencias claras y consistentes; otros presentan historiales dispersos y queries poco específicas.

El objetivo del trabajo es diseñar e implementar un **sistema de recomendación de películas basado en contenido** que, para cada usuario, produzca una lista de 5 películas relevantes. Las decisiones metodológicas -qué información usar, cómo representarla, cómo combinarla- son parte central de la evaluación. Para su resolución deberán formar grupos de hasta 3 personas.

A continuación se presentan algunas preguntas para orientar el trabajo. No es necesario responderlas todas en forma de lista: deben integrarse en el desarrollo del informe y del notebook.

Sobre el corpus

¿Qué información está disponible para representar cada película? ¿Toda es igualmente útil para la tarea? ¿Qué tan completo y limpio es el corpus, y qué consecuencias tiene eso sobre el sistema que se puede construir? ¿Qué limitaciones estructurales del corpus condicionan las decisiones metodológicas posteriores?

Sobre la representación del contenido

¿Cómo hacer para que películas similares queden cerca en el espacio vectorial? ¿Qué entiende el sistema por "similitud" y es eso lo mismo que entiende un usuario? ¿Qué se pierde y qué se gana con la representación elegida? ¿Habría sido mejor otra representación para este corpus y esta tarea?

Sobre el modelado del usuario

¿Cómo representar lo que un usuario quiere ver? ¿El historial y la query aportan el mismo tipo de información? ¿Cómo combinarlas? ¿Debería el sistema tratar igual a un usuario con preferencias claras que a uno con historial disperso? ¿Qué pasa cuando las dos fuentes de información apuntan en direcciones distintas?

Sobre los resultados

¿Las recomendaciones tienen sentido para cada usuario? ¿Hay casos donde el sistema claramente acierta y casos donde falla? ¿A qué se deben esas diferencias: al usuario, al corpus, a la representación, a la forma de combinar las señales? ¿Qué hace el sistema cuando no hay señal clara?

Sobre la evaluación y los límites del enfoque

¿Cómo saber si el sistema recomienda bien con los datos disponibles? ¿Esa métrica es igualmente válida para todos los perfiles? ¿Qué información no se está usando y podría mejorar el sistema? ¿Qué limitaciones tiene un sistema puramente basado en contenido que no podría resolverse con más datos del mismo tipo?

La nota de promoción requiere implementar y comparar al menos dos estrategias de representación distintas, con análisis explícito de sus diferencias.

Fecha de entrega

15 de Junio de 2026.

Entregables

- Notebook reproducible con outputs ejecutados
- Informe en PDF (máximo 10 páginas sin contar código ni outputs)
- Exposición de 10 minutos de los principales resultados

Cronograma para las clases de taller

En ambas clases, el foco de la discusión es la justificación metodológica, no necesariamente la corrección del código.

Clase de Taller 1

Foco: decisiones de diseño y primeros resultados

El grupo debe llegar habiendo explorado el corpus y con al menos una estrategia de representación implementada y corriendo sobre los 14 usuarios. No se espera un sistema terminado sino decisiones tomadas y justificadas.

Durante la clase, cada grupo expone en 10 minutos sobre los siguientes aspectos:

- Qué información del corpus van a usar y por qué
- Qué estrategia de representación eligieron y qué esperan que capture
- Si tienen, qué resultados preliminares obtuvieron para al menos 3 usuarios
- Qué problema concreto están enfrentando o qué decisión todavía no saben cómo tomar

Clase de Taller 2

Foco: resultados completos, evaluación y cierre

El grupo debe llegar habiendo aplicado al menos una estrategia de representación sobre el corpus, generado recomendaciones para los 14 usuarios y realizado una primera evaluación de esos resultados.

Durante la clase, cada grupo expone en 10 minutos sobre los siguientes aspectos:

- Qué estrategia de representación usaron y cómo construyeron el perfil de cada usuario
- Qué muestran los resultados para al menos 2 usuarios: uno donde las recomendaciones parecen coherentes y uno donde no
- Cómo evaluaron los resultados y qué limitaciones le ven a esa evaluación
- Qué problemas encontraron